



Teknoloji Fakültesi

## BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

# GÜVENLİK KONTROL SİSTEMLERİNDE KİŞİSEL KORUYUCU DONANIM (KKD) VE KİMLİK DOĞRULAMA TESPİTİ İÇİN YOLO VE OCR TABANLI ÇİFT AŞAMALI GÖRÜNTÜ İŞLEME SİSTEMİ

### BİTİRME PROJESİ 1. ARA RAPORU

Bilgisayar Mühendisliği Bölümü

**DANIŞMAN**

Prof. Dr. Serhat ÖZEKES

İSTANBUL, 2025

**MARMARA ÜNİVERSİTESİ**  
**TEKNOLOJİ FAKÜLTESİ**  
**BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**

Marmara Üniversitesi Teknoloji Fakültesi Bilgisayar Mühendisliği Öğrencileri Erol Atık, Semih Semerci, Kerime Özge Çetinbaş tarafından “**GÜVENLİK KONTROL SİSTEMLERİNDE KİŞİSEL KORUYUCU DONANIM (KKD) VE KİMLİK DOĞRULAMA TESPİTİ İÇİN YOLO VE OCR TABANLI ÇİFT AŞAMALI GÖRÜNTÜ İŞLEME SİSTEMİ**” başlıklı proje çalışması, xxx tarihinde savunulmuş ve jüri üyeleri tarafından başarılı bulunmuştur.

**Jüri Üyeleri**

Dr. Öğr. Üyesi xxx xxx  
Marmara Üniversitesi  
Prof. Dr. Xxx xxx  
Marmara Üniversitesi  
Prof. Dr. Xxx xxx  
Marmara Üniversitesi

**(Danışman)**

(Üye)

(Üye)

(İMZA).....

(İMZA).....

(İMZA).....

## ÖNSÖZ

Proje çalışmamız süresince karşılaştığım bütün problemlerde, sabırla yardım ve bilgilerini esirgemeyen, tüm desteğini sonuna kadar yanımda hissettiğim değerli hocalarım, sayın Dr. Öğr. Üyesi Xxx xxx ve sayın Prof. Dr. Xxx xxx' a en içten teşekkürlerimi sunarım.

Bu proje çalışması fikrinin oluşması ve ortaya çıkmasındaki önerisi ve desteğinden dolayı değerli hocam Dr. Öğr. Üyesi Xxx xxx' a teşekkür ederim.

Proje çalışmam sırasında maddi ve manevi desteklerini esirgemeyen okul içerisinde ve okul dışında her zaman yanımda olan değerli çalışma arkadaşlarım ve hocalarım Doç. Dr. Xxx xxx ve Dr. Öğr. Üyesi ' xxx xxx a sonsuz teşekkürlerimi sunarım.

# İÇİNDEKİLER

1. GİRİŞ.....	1
1.1. Proje Çalışmasının Amacı ve Önemi .....	2
1.2. Literatür Taraması .....	2
1.3. Problem Tanımı .....	4
1.4. Proje Kapsamı ve Sınırlamaları .....	5
2. YÖNTEM .....	5
2.1. KKD Tespiti ve YOLOv5'in Çalışma Prensipleri.....	5
2.2. YOLOv5 Tabanlı KKD Tespitinde Model ve Sürüm Seçimi.....	7
2.3. OCR ile Kimlik Doğrulama Yöntemi .....	8
2.4. Veri Seti ve Etiketleme Süreci.....	9
2.5. YOLOv5 Modelinin Eğitim Süreci .....	10
3. BULGULAR VE TARTIŞMA .....	12
3.1. Model Performansına Genel Bakış .....	12
3.2. Sınıf Bazlı Hata Analizi.....	13
3.3. Kayıp Fonksiyonları ve Öğrenme Eğrisi .....	14
3.4. İnferens (Tahmin) Sonuçları Üzerine Gözlemler .....	15
4. SONUÇLAR .....	16

# ÖZET

## **GÜVENLİK KONTROL SİSTEMLERİNDE KİŞİSEL KORUYUCU DONANIM (KKD) VE KİMLİK DOĞRULAMA TESPİTİ İÇİN YOLO VE OCR TABANLI ÇİFT AŞAMALI GÖRÜNTÜ İŞLEME SİSTEMİ**

Bu proje çalışmasında, başta sanayi ve inşaat sektörleri olmak üzere güvenlik ve erişim kontrolünün kritik olduğu yüksek riskli iş ortamlarında kullanılmak üzere, kişisel koruyucu donanım (KKD) tespiti ve kimlik doğrulama süreçlerini otomatikleştiren, YOLO ve OCR tabanlı çift aşamalı bir görüntü işleme sistemi geliştirilmiştir.

Sistemin ilk aşamasında, derin öğrenme temelli YOLO algoritması kullanılarak çalışanların kask, gözlük, eldiven gibi gerekli KKD ekipmanlarını takıp takmadıkları gerçek zamanlı olarak tespit edilmektedir. İkinci aşamada ise OCR teknolojisi ile personel kimlik kartı üzerindeki bilgiler okunarak sistemde kayıtlı yetkili kişilerle karşılaştırılmakta ve doğrulama işlemi gerçekleştirilmektedir. Bu yaklaşım, iş güvenliği standartlarına uyumu artırmayı, yetkisiz erişimi engellemeyi ve manuel denetim yükünü azaltarak operasyonel verimliliği yükseltmeyi amaçlamaktadır.

Sistem, GPU hızlandırmalı gerçek zamanlı nesne algılama altyapısı sayesinde hızlı ve doğru KKD kontrolü sağlar. Kimlik tanıma sürecinde ise OCR, arka planda çalışan bir doğrulama modülü ile entegre edilmiştir; bu modül, kimlikten alınan bilgileri sistemdeki yetkili personel verileriyle eşleştirerek güvenliği garanti altına alır. Bu mimari sayesinde geliştirilen sistem, iş güvenliğinin öncelikli olduğu farklı sanayi ortamlarında ölçeklenebilir ve verimli bir çözüm olarak kullanılabilir.

**Mart, 2025**

**Öğrenciler**

**Erol ATİK – 170421046**

**Semih SEMERCİ – 170422824**

**Kerime Özge ÇETİNBAŞ – 100719017**

# **ABSTRACT**

## **A TWO-STAGE IMAGE PROCESSING SYSTEM BASED ON YOLO AND OCR FOR PERSONAL PROTECTIVE EQUIPMENT (PPE) AND IDENTITY VERIFICATION IN SECURITY CONTROL SYSTEMS**

In this project, a dual-stage image processing system based on YOLO and OCR technologies has been developed to automate personal protective equipment (PPE) detection and identity verification processes in high-risk work environments, particularly in industrial and construction sectors where safety and access control are critical.

In the first stage of the system, the YOLO algorithm, based on deep learning, is used to detect in real time whether workers are wearing necessary PPE such as helmets, goggles, and gloves. In the second stage, OCR technology is employed to extract and validate information from the personnel's ID cards. This approach aims to enhance compliance with safety standards, prevent unauthorized access, and increase operational efficiency by reducing the burden of manual inspections.

The system utilizes a real-time object detection framework supported by GPU acceleration, ensuring fast and accurate PPE verification. For identity recognition, OCR is integrated with a backend verification module that cross-checks extracted data with authorized personnel records. Through this architecture, the proposed system offers a scalable and efficient solution adaptable to various industrial environments where occupational safety is a top priority.

**March, 2025**

**Students**

**Erol ATİK – 170421046**

**Semih SEMERCİ – 170422824**

**Kerime Özge ÇETİNBAS – 100719017**

**SEMBOLLER**

## KISALTMALAR

<b>KKD</b>	: Kişisel Koruyucu Donanım
<b>OCR</b>	: Optical Character Recognition (Optik Karakter Tanıma)
<b>YOLO</b>	: You Only Look Once (Bir Kez Bakarak Algılama)
<b>YOLOv5</b>	: You Only Look Once, versiyon 5 (nesne algılama modeli)
<b>GPU</b>	: Graphics Processing Unit (Grafik İşlem Birimi)
<b>PPE</b>	: Personal Protective Equipment (Kişisel Koruyucu Donanım – İngilizce)
<b>AI</b>	: Artificial Intelligence (Yapay Zekâ)
<b>ID</b>	: Identity (Kimlik)
<b>CNN</b>	: Convolutional Neural Network (Evrişimsel Sinir Ağı)
<b>NMS</b>	: Non-Maximum Suppression (Aşırı Tespiti Engelleme Algoritması)
<b>API</b>	: Application Programming Interface (Uygulama Programlama Arayüzü)
<b>IOU</b>	: Intersection over Union (Kesişim / Birleşim Oranı- nesne tespiti metriği)
<b>FPS</b>	: Frames Per Second (Saniyedeki Kare Sayısı- gerçek zamanlılık ölçütü)
<b>SGD</b>	: Stochastic Gradient Descent (Rastgele Gradyan Azaltma)
<b>lr0</b>	: Initial Learning Rate (Başlangıç Öğrenme Oranı)
<b>mAP</b>	: Mean Average Precision (Ortalama Doğruluk Oranı)
<b>HSV</b>	: Hue-Saturation-Value (Renk tonu, doygunluk, parlaklık renk uzayı)
<b>T4 GPU</b>	: NVIDIA Tesla T4 Grafik İşlemci (Colab GPU donanımı)



## ŞEKİL LİSTESİ

Şekil 2.1 KKD Veri Setinden Örnek Görseller	20
Şekil 3.1 Nokta Ortalama Doğruluk (mAP@0.5:0.95) Değerlerinin Epoch Boyunca Değişimi	23
Şekil 3.2 Modelin Sınıflandırma Performansına Ait Karmaşıklık Matrisi	24
Şekil 3.4 DLP3000 geliştirme modülü Nesne Tespit Kayıp Fonksiyonu (val/obj_loss) Grafiği	25
Şekil 3.5 Modelin Tahmin Sonuçlarına Ait Görsel Örnek	26

## TABLO LİSTESİ

## 1. GİRİŞ

Günümüzde iş güvenliği, özellikle sanayi ve inşaat gibi yüksek riskli çalışma alanlarında hem çalışanların sağlığını korumak hem de iş kazalarını önlemek adına büyük bir önem taşımaktadır. İş kazalarının önemli bir kısmı, kişisel koruyucu donanım (KKD) kullanımının yetersizliği veya ihmalinden kaynaklanmaktadır. Bu nedenle, KKD kullanımının düzenli ve doğru bir şekilde denetlenmesi, iş güvenliği standartlarına uyum açısından vazgeçilmezdir [1].

Aynı zamanda, sadece yetkili kişilerin belirli alanlara erişimini sağlamak, güvenlik açıklarını önlemek için bir diğer kritik unsurdur. Kimlik doğrulama süreçlerinin hızlı, güvenilir ve otomatik hale getirilmesi, özellikle yoğun personel trafiğinin olduğu ortamlarda büyük kolaylık sağlamaktadır. Geleneksel yöntemlerle yapılan manuel kontroller, zaman alıcı olmanın yanı sıra insan hatalarına da açıktır [2].

Yapay zekâ ve bilgisayarla görme (computer vision) alanındaki gelişmeler, bu alandaki denetim süreçlerini otomatikleştirmek adına yeni fırsatlar sunmaktadır. Derin öğrenme tabanlı nesne algılama algoritmaları, özellikle YOLO (You Only Look Once) gibi modeller, gerçek zamanlı ve yüksek doğruluk oranlarıyla görüntü üzerinde nesne tespiti yapabilmektedir [3]. Bu teknolojiler sayesinde işçilerin KKD ekipmanlarını takıp takmadığı anlık olarak belirlenebilmekte ve eksik donanım kullanımı anında tespit edilebilmektedir.

Ayrıca, optik karakter tanıma (OCR) teknolojisi sayesinde kimlik kartlarındaki bilgiler görüntü üzerinden okunarak dijital olarak doğrulanabilir hale gelmiştir. Bu sayede erişim kontrol sistemleri daha güvenli ve hızlı bir yapıya kavuşturulmuştur [4].

Bu proje, hem KKD kullanımının tespitini hem de kimlik doğrulama sürecini aynı sistemde birleştirerek, sahada kullanılacak etkili, gerçek zamanlı ve düşük maliyetli bir güvenlik çözümü sunmayı hedeflemektedir. Sistem, güvenlik standartlarına uyumu artırırken manuel iş yükünü azaltmakta, böylece insan kaynağının daha verimli kullanılmasına olanak tanımaktadır.

### **1.1. Proje Çalışmasının Amacı ve Önemi**

Sanayi ve inşaat sektörlerinde, çalışan güvenliğinin sağlanması ve yetkisiz erişimlerin önlenmesi, iş yerlerinde güvenlik politikalarının temelini oluşturmaktadır. Özellikle tehlikeli iş ortamlarında, kişisel koruyucu donanım (KKD) kullanımının zorunlu tutulması; iş kazalarının önlenmesi ve çalışanların sağlığının korunması açısından hayati bir rol oynamaktadır [1]. Bununla birlikte, yalnızca yetkili personelin belirli alanlara giriş yapabilmesi hem fiziksel güvenlik hem de veri güvenliği açısından kritik öneme sahiptir.

Bu çalışmanın temel amacı; iş güvenliği standartlarını otomatik yollarla denetlemek ve manuel kontrol süreçlerinden kaynaklanan zaman kaybı ile insan hatalarını minimize etmektir. Bu hedef doğrultusunda geliştirilen sistem, KKD kullanımını gerçek zamanlı olarak tespit eden derin öğrenme tabanlı bir YOLO algoritması [2] ve kimlik doğrulama işlemlerini gerçekleştiren OCR tabanlı bir tanıma mekanizması içermektedir [4]. Böylece, hem donanım eksiklikleri anında tespit edilebilmekte hem de çalışma alanlarına yalnızca yetkili kişilerin erişimi sağlanmaktadır.

Geleneksel yöntemlerle yapılan güvenlik denetimleri çoğu, zaman zaman alıcı, personel yoğunluklu ve tutarsız olabilmektedir [5]. Otomatik sistemler ise bu süreci daha hızlı, sürekli ve daha az kaynak tüketimi ile gerçekleştirme imkânı sunmaktadır. Ayrıca, iş kazalarının önemli bir bölümünün KKD kullanılmaması veya eksik kullanılması nedeniyle gerçekleştiği yapılan çalışmalarla ortaya konmuştur [6]. Bu nedenle, görüntü işleme tekniklerinin bu alanda kullanılmaya başlanması, iş güvenliği alanında yeni bir dönüşümün kapısını aralamaktadır.

Bu proje çalışması hem kamu hem de özel sektörde uygulanabilirliği yüksek olan, düşük maliyetli, ölçeklenebilir ve entegre edilebilir bir sistem önerisi sunarak; iş sağlığı ve güvenliği süreçlerine teknolojik bir katkı sağlamayı hedeflemektedir. Aynı zamanda, dijital dönüşüm kapsamında yapay zekâ destekli denetim sistemlerinin yaygınlaştırılmasına da öncülük edebilecek bir model ortaya koymaktadır.

### **1.2. Literatür Taraması**

Görüntü işleme ve yapay zekâ tabanlı denetim sistemleri, son yıllarda iş sağlığı ve güvenliği alanında yaygın şekilde araştırılan ve geliştirilen teknolojilerden biri haline

gelmiştir. Özellikle yüksek risk içeren iş alanlarında, çalışanların kişisel koruyucu donanım (KKD) kullanımının denetlenmesi hem yasal zorunluluklar hem de iş kazalarının azaltılması açısından kritik öneme sahiptir [1].

Derin öğrenme temelli nesne algılama algoritmaları, bu tür denetim sistemlerinde öne çıkan teknolojilerdendir. Özellikle YOLO (You Only Look Once) algoritması, gerçek zamanlı nesne tespiti kabiliyeti sayesinde KKD denetimi gibi sahaya dayalı uygulamalarda yaygın olarak tercih edilmektedir. Redmon ve Farhadi tarafından geliştirilen YOLOv3 mimarisi, düşük gecikmeli, hızlı ve çoklu nesne tanımlamasına uygun yapısı sayesinde iş güvenliği sistemlerine kolayca entegre edilebilmektedir [2]. Muhammad ve arkadaşları (2021), PPE (Personal Protective Equipment) tespiti üzerine yaptıkları kapsamlı çalışmada, derin öğrenme tabanlı modellerin insan gözlemine göre çok daha tutarlı ve hızlı sonuçlar verdiğini göstermiştir [3].

Kimlik doğrulama süreçlerinde ise OCR (Optical Character Recognition) teknolojileri ön plana çıkmaktadır. OCR sistemleri, görsel veriler üzerinden metin çıkartımı yaparak belge tanıma, arşivleme ve yetkilendirme gibi birçok alanda kullanılmaktadır. Tesseract OCR, açık kaynak kodlu ve yaygın olarak kullanılan bir motor olup, özellikle kimlik kartı gibi standart formatlı belgelerden yüksek doğrulukta metin okuma kabiliyeti sunmaktadır [4].

Türkiye’de yapılan çalışmalar da bu alandaki gelişmelere paralel ilerlemektedir. Arıkan ve Demir (2020), iş güvenliği denetim süreçlerinin etkinliğini sorguladıkları araştırmalarında, manuel kontrollerin sınırlı kalabildiğini ve teknolojik çözümlerin süreç verimliliğini artırabileceğini vurgulamışlardır [5]. Benzer şekilde Gül ve Gökçe (2019), KKD kullanımının iş kazaları üzerindeki etkisini inceledikleri çalışmalarında, doğru donanım kullanımının iş kazası oranlarını doğrudan etkilediğini göstermiştir [6].

Yapılan bu çalışmalar, görüntü işleme tabanlı denetim sistemlerinin yalnızca teorik olarak değil, pratikte de uygulanabilir olduğunu ortaya koymakta ve geliştirilecek bu projenin hem bilimsel hem de sektörel bir boşluğu dolduracağını desteklemektedir.

### 1.3. Problem Tanımı

İş güvenliği, özellikle sanayi ve inşaat gibi yüksek risk barındıran sektörlerde, çalışanların sağlığını korumak ve iş kazalarını en aza indirmek açısından kritik öneme sahiptir. Ancak sahada yapılan gözlemler, kişisel koruyucu donanımın (KKD) eksik ya da hatalı kullanılması nedeniyle ciddi yaralanmaların ve kazaların hâlâ yaygın olduğunu göstermektedir. Bu durum, KKD kullanımının yalnızca zorunlu tutulmasının değil, aynı zamanda düzenli ve doğru şekilde denetlenmesinin de gerekli olduğunu ortaya koymaktadır [1].

Günümüzde bu denetim süreçleri genellikle insan gözüyle yapılmakta, bu da hem zaman kaybına hem de ciddi ölçüde insan hatasına yol açmaktadır [5]. Aynı şekilde, kimlik doğrulama süreçleri de çoğu zaman manuel kart kontrolü ya da basit geçiş sistemlerine dayalı olup; sahte kart kullanımı, yanlış personel erişimi gibi ciddi güvenlik açıklarına neden olabilmektedir. Özellikle büyük ve karmaşık iş sahalarında bu denetimleri manuel olarak sürdürebilmek hem maliyetli hem de operasyonel olarak verimsizdir.

Projenin ele aldığı temel problem, bu iki önemli güvenlik mekanizmasının (KKD kontrolü ve kimlik doğrulama) insan bağımlı ve düşük verimli yöntemlerle yapılmasıdır. Amaç; bu süreçleri otomatikleştirerek gerçek zamanlı hale getirmek, hem iş güvenliği standartlarına uyumu artırmak hem de yetkisiz erişimi önlemektir.

Sistem, sahada kurulu kameralardan alınan görüntüler üzerinden çalışanların KKD donanımlarını (kask, gözlük, eldiven vb.) tespit etmekte ve eş zamanlı olarak personelin kimlik kartı üzerindeki bilgileri OCR teknolojisi ile okuyarak yetki doğrulaması yapmaktadır. Bu bağlamda projenin ana hedefleri şunlardır:

- KKD ekipmanlarının eksiksiz ve doğru şekilde kullanımının otomatik olarak kontrol edilmesi,
- Kimlik doğrulamanın sahada görsel içerikler üzerinden yapılması,
- Manuel güvenlik denetiminin yükünü azaltarak verimliliğin artırılması,
- İnsan hatalarının en aza indirilmesi ve güvenlik açıklarının kapatılması.

Bu sistemin prototipi, özellikle yoğun insan trafiğine sahip fabrika, şantiye gibi ortamlarda kullanılmak üzere geliştirilmiştir. Proje kapsamında kullanılan yaklaşımlar, iş sahasına özel varsayımlar (örn. belirli KKD tipi zorunluluğu), kamera konumları ve kimlik kartı

tasarımı gibi çeşitli sınırlamalara göre uyarlanmıştır.

#### **1.4. Proje Kapsamı ve Sınırlamaları**

Bu proje, iş güvenliği denetimlerinin otomatikleştirilmesine yönelik çift aşamalı bir görüntü işleme sistemi geliştirilmesini hedeflemektedir. Projenin genel kapsamı; kişisel koruyucu donanım (KKD) kullanımının tespit edilmesi ve kimlik doğrulama süreçlerinin görüntü tabanlı olarak gerçekleştirilmesidir. Geliştirilmesi planlanan sistemde, YOLO algoritması ile çalışanların KKD ekipmanlarını kullanıp kullanmadığı algılanacak, OCR teknolojisi ile kimlik kartlarındaki bilgiler okunarak yetki kontrolü yapılacaktır.

Proje henüz geliştirme aşamasının başında olduğundan, detaylı sistem mimarisi, kullanılacak veri seti, donanım özellikleri ve yazılım mimarisi gibi teknik bileşenler ilerleyen süreçte netleşecektir. Bu nedenle, bu raporda yer alan kapsam ve sınırlamalar, ön değerlendirmelere ve planlamalara dayalı olarak sunulmuştur.

İlerleyen aşamalarda, sistemin kullanılacağı ortam koşulları, kamera yerleşimi, veri çeşitliliği, gerçek zamanlı performans gereksinimleri ve entegrasyon olanakları göz önünde bulundurularak kapsam yeniden değerlendirilecektir.

## **2. YÖNTEM**

### **2.1. KKD Tespiti ve YOLOv5'in Çalışma Prensibi**

Projenin ilk aşamasında, çalışanların kişisel koruyucu donanım (KKD) kullanımlarının otomatik olarak tespit edilmesi amacıyla YOLOv5 nesne algılama modeli tercih edilmiştir. YOLO (You Only Look Once), tek bir ileri geçişte (single-shot) tüm nesneleri tespit edebilen, gerçek zamanlı ve yüksek doğruluk oranlarına sahip bir derin öğrenme modelidir [2]. Bu özellikleri sayesinde özellikle sahada anlık denetim gerektiren iş güvenliği uygulamalarında ideal bir çözüm sunmaktadır.

YOLOv5'in çalışma prensibi genel olarak aşağıdaki adımlara dayanmaktadır:

**Girdi Görüntüsü:** Model, kameradan aldığı görüntüyü sabit bir boyuta (örneğin 640x640 piksel) yeniden boyutlandırarak işlemeye başlar.

**Özellik Çıkartımı:** Girdi görüntüsü, konvolüsyonel sinir ağı (CNN) katmanları aracılığıyla işlenir. Bu aşamada model; kenarlar, dokular, şekiller gibi görüntüdeki temel özellikleri çıkarır ve derin temsillere dönüştürür.

**Çoklu Çıkış Katmanları:** YOLOv5, çıktıyı üç farklı çözünürlük seviyesinde üretir. Bu, modelin hem küçük hem büyük nesneleri aynı anda tespit edebilmesini sağlar. Her bir seviye farklı boyutlardaki nesneler için optimize edilmiştir.

**Sınıf ve Konum Tahmini:** Görüntü, sabit grid'lere bölünür ve her grid hücresi içerisinde nesne olup olmadığı tahmin edilir. Eğer varsa, nesnenin sınıfı, konumu (bounding box koordinatları) ve güven skoru belirlenir.

**Non-Maximum Suppression (NMS):** Aynı nesnenin birden fazla kutu ile tespit edilmesini önlemek amacıyla NMS algoritması uygulanır. Bu işlem yalnızca en yüksek güven skoruna sahip olan tespiti korur, diğerlerini eler.

**Sonuçların Sunumu:** Nihai olarak model, tespit edilen nesnelerin sınıflarını, konum bilgilerini ve güven skorlarını kullanıcıya sunar.

YOLOv5'in bu hızlı ve verimli yapısı, projede hedeflenen gerçek zamanlı KKD kontrol sistemi için büyük bir avantaj sağlamaktadır. Modelin yüksek hızda çalışabilmesi, anlık tespitlerin yapılmasına ve olası güvenlik ihlallerinin anında raporlanmasına olanak tanımaktadır.



## 2.2. YOLOv5 Tabanlı KKD Tespitinde Model ve Sürüm Seçimi

Bu projede, kişisel koruyucu donanım (KKD) tespiti amacıyla YOLOv5 nesne algılama modeli tercih edilmiştir. Seçimin temelinde, modelin gerçek zamanlı çalışabilme yeteneği, yüksek doğruluk oranları ve esnek mimarisi yer almaktadır. YOLO (You Only Look Once) algoritmaları, tek bir ileri geçiş (single forward pass) ile nesne tespiti gerçekleştirmesi sayesinde, özellikle zaman kritik uygulamalarda sıkça tercih edilmektedir [2].

YOLOv5, PyTorch tabanlı açık kaynak bir mimariye sahip olup; eğitim kolaylığı, transfer öğrenme desteği, hiperparametre ayarlanabilirliği ve gömülü sistemlere uyarlanabilirliği ile önceki sürümlerden ayrılmaktadır. Ayrıca, modelin farklı konfigürasyonları (YOLOv5s, YOLOv5m, YOLOv5l, YOLOv5x), kullanıcıların ihtiyaca göre doğruluk-hız dengesini belirlemesine olanak tanımaktadır [3].

Modelin proje kapsamında tercih edilmesini destekleyen başlıca avantajları aşağıda özetlenmiştir:

- **Gerçek Zamanlı Performans:** YOLOv5, optimize edilmiş yapısı sayesinde düşük gecikme süresiyle çalışmakta, bu da sahada anlık KKD kontrolü gibi uygulamalarda etkinliğini artırmaktadır.
- **Yüksek Doğruluk Oranı:** Derin mimarisi ve çok ölçekli özellik haritaları sayesinde farklı boyutlardaki nesnelerin doğru şekilde algılanmasına olanak tanır.
- **Modüler ve Taşınabilir Yapı:** Küçük model boyutları sayesinde mobil cihazlar veya düşük donanımlı sistemlerde çalıştırılabilme esnekliği sunar.
- **Transfer Öğrenme Desteği:** Önceden eğitilmiş ağırlıkların kullanımıyla, sınırlı veriyle bile yüksek performansa ulaşmak mümkündür.
- **Kolay Özelleştirilebilirlik:** PyTorch tabanlı mimarisi sayesinde yeni veri kümeleriyle yeniden eğitilmesi ve hiperparametre ayarlarının düzenlenmesi oldukça pratiktir.
- **Geniş Topluluk Desteği:** YOLOv5, açık kaynak olması ve yaygın kullanımı nedeniyle güçlü bir geliştirici topluluğu tarafından sürekli güncellenmekte ve desteklenmektedir.

YOLOv5'in v3 ve v4 gibi önceki sürümlerine kıyasla sunduğu bu avantajlar, projede hedeflenen gerçek zamanlı tespit, düşük donanım gereksinimi ve eğitim kolaylığı kriterleri ile örtüşmektedir. Bu bağlamda, KKD tespiti modülünde YOLOv5'in kullanılması, teknik ve operasyonel gereksinimlerle uyumlu, yerinde bir tercih olarak değerlendirilmiştir.

### 2.3. OCR ile Kimlik Doğrulama Yöntemi

Projenin ikinci aşaması, çalışma alanlarına yalnızca yetkili kişilerin erişiminin sağlanması amacıyla görsel veriye dayalı kimlik doğrulama sisteminin geliştirilmesini kapsamaktadır. Bu kapsamda, personelin taşıdığı kimlik kartları üzerindeki yazılı bilgilerin, kamera görüntüsü üzerinden otomatik olarak okunması hedeflenmektedir. Bu işlem, Optik Karakter Tanıma (Optical Character Recognition- OCR) teknolojisi ile gerçekleştirilir.

OCR, dijital görüntüler üzerinde yer alan metinleri tanıyıp, dijital metne dönüştüren bir bilgisayarla görme tekniğidir. Bu teknoloji, belge arşivleme, otomatik fatura işleme ve kimlik doğrulama gibi birçok alanda aktif olarak kullanılmaktadır. Proje kapsamında açık kaynaklı ve yaygın kullanıma sahip olan Tesseract OCR motoru tercih edilmiştir. Tesseract, metin bloklarını tespit ederek bu alanlar içindeki karakterleri tanımakta ve yüksek doğrulukla dijital çıktıya dönüştürmektedir [4].

Kimlik doğrulama işlemi genel olarak şu adımlar ile gerçekleşmektedir:

- **Görüntü Alımı:** Kamera görüntüsünden, kimlik kartının bulunduğu bölge sistem tarafından tespit edilir.
- **Görüntü Ön İşleme:** OCR doğruluğunu artırmak amacıyla görüntü gri tonlamaya (grayscale), gürültü azaltmaya ve eşikleme gibi ön işleme tekniklerine tabi tutulur.
- **Metin Tanıma:** Ön işleme sonrası elde edilen net görüntü, Tesseract OCR motoruna gönderilerek metin verisi elde edilir.
- **Veri Doğrulama:** OCR çıktısı, sistemde kayıtlı yetkili personel verisiyle karşılaştırılır. Eşleşme sağlanmayan kimlikler için sistem uyarı üretir ve erişim engellenir.

OCR kullanımının projeye sağladığı temel katkılar şunlardır:

- **Manuel Kontrol İhtiyacını Azaltır:** Kimlik kartlarının görsel olarak okunması, elle yapılan kontrol süreçlerinin ortadan kalkmasını sağlar.
- **Gerçek Zamanlı Doğrulama:** Kamera ile entegre çalışan sistem, anlık doğrulama

işlemleri gerçekleştirebilir.

- **Sistem Güvenliğini Artırır:** Yanıltıcı kart kullanımı, görsel eşleşme ve metin analizi sayesinde minimize edilir.
- **Yaygın ve Açık Kaynak Teknoloji:** Tesseract gibi güçlü bir OCR motorunun kullanımı hem geliştirme kolaylığı hem de maliyet avantajı sağlar.

Bu yöntem sayesinde, yalnızca yetkili personelin belirlenen alanlara erişimi sağlanacak ve kimlik kontrol süreçleri dijital, hızlı ve güvenilir bir yapıya kavuşturulacaktır.

## 2.4. Veri Seti ve Etiketleme Süreci

Projenin ilk aşamasında, nesne algılama modelinin eğitimi için özel olarak oluşturulmuş ve optimize edilmiş bir görsel veri seti kullanılmıştır. Bu veri seti, hem açık kaynak kaynaklardan temin edilen görüntülerle hem de sahaya özgü senaryolarla zenginleştirilmiş, gerçek uygulama ortamlarını temsil edecek şekilde çeşitlendirilmiştir.

Veri seti oluşturma süreci aşağıdaki adımları içermektedir:

**Veri Toplama:** Toplamda yaklaşık 18.000 görüntüden oluşan veri setinin bir kısmı, açık kaynaklı veri seti paylaşım platformu olan Roboflow üzerinden elde edilmiştir. Bu platform, farklı kategorilerde etiketli görseller sağlayarak model eğitimi için kullanılabilir içerikler sunmaktadır. Roboflow'dan alınan görseller projeye özel olarak seçilmiş ve ihtiyaçlara göre filtelenmiştir.


**Kendi Verimizin Üretilmesi:** Proje kapsamında temin edilen KKD ürünleri (kask, gözlük, eldiven vb.) ile farklı açılardan ve farklı senaryolarda görseller toplanmıştır. Farklı kişilere ait görüntüler, çeşitli arka planlar ve aydınlatma koşulları kullanılarak veri çeşitliliği artırılmıştır. Böylece modelin daha geniş bir uygulama ortamında genelleme yapabilmesi hedeflenmiştir.

**Etiketleme Süreci:** İlk olarak, Roboflow'un sunduğu otomatik etiketleme modelleri kullanılarak görsellere etiketler atanmıştır. Ancak bu etiketlerin bazıları eksik veya hatalı olduğundan, etiketleme süreci manuel olarak gözden geçirilmiştir. Bu süreçte LabelImg adlı açık kaynak bir etiketleme aracı kullanılmıştır. LabelImg, görüntüler üzerinde kullanıcıların elle sınırlayıcı kutular (bounding box) çizmesini ve sınıf isimlerini girmesini sağlayan kullanıcı dostu bir yazılımdır. Veriler, YOLOv5 formatına uygun şekilde .txt

dosyaları olarak kaydedilmiştir.

**Veri Bölme:** Veri seti, modelin eğitimi ve doğrulaması için %80 eğitim ve %20 doğrulama (validation) oranında ikiye ayrılmıştır. Bu ayrım, modelin hem öğrenme hem de genelleme başarısını test edebilmek adına önem arz etmektedir.

#### KKD VERİ SETİ



**Şekil 2.1- KKD Veri Setinden Örnek Görseller**

## 2.5. YOLOv5 Modelinin Eğitim Süreci

Model eğitimi aşamasında, YOLOv5 mimarisinin etkin bir şekilde öğrenme gerçekleştirmesi ve genel doğruluk performansının artırılması amacıyla çeşitli hiperparametreler kullanılmıştır. Bu parametreler, modelin hem hızlı hem de doğru bir şekilde konverjans sağlamasına olanak tanımıştır.

Eğitim sürecinde Stochastic Gradient Descent (SGD) optimizasyon algoritması tercih edilmiştir. Bu algoritma; öğrenme oranı, momentum ve ağırlık düşüşü gibi temel parametrelerle yapılandırılmıştır. Başlangıç öğrenme oranı ( $lr_0$ ) 0,01 olarak belirlenmiş, öğrenme oranı zamanla OneCycleLR stratejisi ile dinamik olarak güncellenmiştir. Böylece

model, eğitim süresi boyunca farklı evrelerde değişen öğrenme hızlarına adapte olmuştur.

Momentum değeri 0.937 olarak seçilmiş, bu sayede geçmiş gradyan güncellemeleri daha fazla dikkate alınarak daha stabil bir öğrenme süreci elde edilmiştir. Ağırlık düşüşü (weight decay) parametresi ise 0.0005 olarak belirlenmiştir; bu da modelin aşırı öğrenmesini (overfitting) engelleyerek genelleme kabiliyetini artırmıştır.

Modelin erken evrelerinde daha yavaş öğrenmesini sağlayan bir warmup (ısınma) süreci uygulanmıştır. Bu süreç 3 epoch boyunca devam etmiş ve bu süre zarfında momentum değeri 0.8'e, bias learning rate ise 0.1'e sabitlenmiştir.

Kayıp fonksiyonu ile ilişkili hiperparametreler de model performansını doğrudan etkileyecek şekilde optimize edilmiştir. Bu parametreler şu şekildedir:

- Box loss gain (box): 0.05
- Class loss gain (cls): 0.5
- Object loss gain (obj): 1.0
- Focal loss (fl\_gamma): 0.0

Bu değerler, modelin konum tahminleri ile sınıf tahminleri arasındaki hata katkılarını dengelemek üzere yapılandırılmıştır.

Modelin veri çeşitliliğini artırmak ve daha sağlam bir genelleme yeteneği kazanmasını sağlamak amacıyla çeşitli veri artırma (data augmentation) teknikleri uygulanmıştır. Bu teknikler arasında:

- Görüntülerin yatay olarak çevrilmesi (flip left-right) %50 olasılıkla,
- Görüntülerin birleştirilmesi (mosaic) %100 olasılıkla,
- HSV uzayında renk varyasyonları (hsv\_h: 0.015, hsv\_s: 0.7, hsv\_v: 0.4) yer almaktadır.

Eğitim süreci, toplamda 200 epoch olarak planlanmış ve her bir adımda 16 görüntüden oluşan mini-batch'lerle yürütülmüştür. Bu yapı hem modelin daha kararlı öğrenmesini hem de bellek verimliliğini artırmayı amaçlamaktadır.

Eğitim işlemleri, Google'ın sunduğu Colab Pro platformu üzerinde gerçekleştirilmiştir. Colab Pro, kullanıcılarına daha uzun oturum süresi, daha güçlü donanım ve öncelikli


kaynak erişimi sunmaktadır. Bu bağlamda, model eğitimi sırasında NVIDIA T4 GPU kullanılmıştır. T4 GPU, derin öğrenme modelleri için optimize edilmiş güçlü bir grafik işlem birimi olup; yüksek paralel işlem kabiliyeti sayesinde eğitim süresini ciddi şekilde azaltmıştır. Bu sayede modelin eğitimi daha kısa sürede tamamlanmış ve hiperparametrelerin test edilmesi süreci hızlandırılmıştır.

### **3. BULGULAR VE TARTIŞMA**

Model eğitimi tamamlandıktan sonra, doğrulama verisi üzerinde yapılan değerlendirmeler doğrultusunda çeşitli çıktı analizleri gerçekleştirilmiştir. Aşağıda sunulan bulgular, hem modelin genel başarı durumunu hem de sınıf bazlı performansını yansıtmaktadır.

#### **3.1. Model Performansına Genel Bakış**

YOLOv5 modeli ile gerçekleştirilen nesne tespiti uygulamasında,  $mAP@0.5-0.95$  değeri temel değerlendirme ölçütü olarak alınmıştır. Bu metrik, modelin tahmin ettiği sınırlayıcı kutular (bounding boxes) ile etiketlenmiş gerçek kutular arasındaki kesişim oranlarına (IoU) dayalı olarak hesaplanmakta ve nesne tespitinde doğruluk seviyesini ölçmektedir. Elde edilen sonuçlara göre modelin ortalama doğruluğu genel anlamda yeterli seviyededir. Eğitim süreci boyunca mAP değeri sürekli artış göstermiş, bu da modelin öğrenme eğrisinin sağlıklı ilerlediğini göstermektedir.



**Şekil 3.1- Ortalama Doğruluk (mAP@0.5:0.95) Değerlerinin Epoch Boyunca Değişimi**

mAP değerindeki sürekli artış, modelin genel doğruluğunun her adımda iyileştiğini ve öğrenmenin başarıyla gerçekleştiğini göstermektedir.

### 3.2. Sınıf Bazlı Hata Analizi

Modelin sınıflar bazında gösterdiği performans incelendiğinde, özellikle “vest” ve “human” sınıflarında hata oranlarının diğer sınıflara göre daha yüksek olduğu gözlemlenmiştir. Bu iki sınıf arasında sınıflandırma hataları meydana gelmiş; model bazı örneklerde bu sınıfları birbirine karıştırmıştır. Ayrıca, her iki sınıfın zaman zaman arka plan (background) ile karıştırıldığı durumlar da tespit edilmiştir. Bu durum, bu iki sınıfın görsel olarak birbirine yakın alanlara sahip olmasından ve benzer görsel özellikler taşımasından kaynaklanıyor olabilir.

Aşağıdaki matriste modelin sınıflar arası doğruluğu görselleştirilmiştir. Özellikle “vest” ve “human” sınıflarında çapraz tahmin oranlarının yüksek olduğu gözlemlenmektedir. Bu durum sınıf benzerliği ve arka plan çeşitliliği ile ilişkilidir.

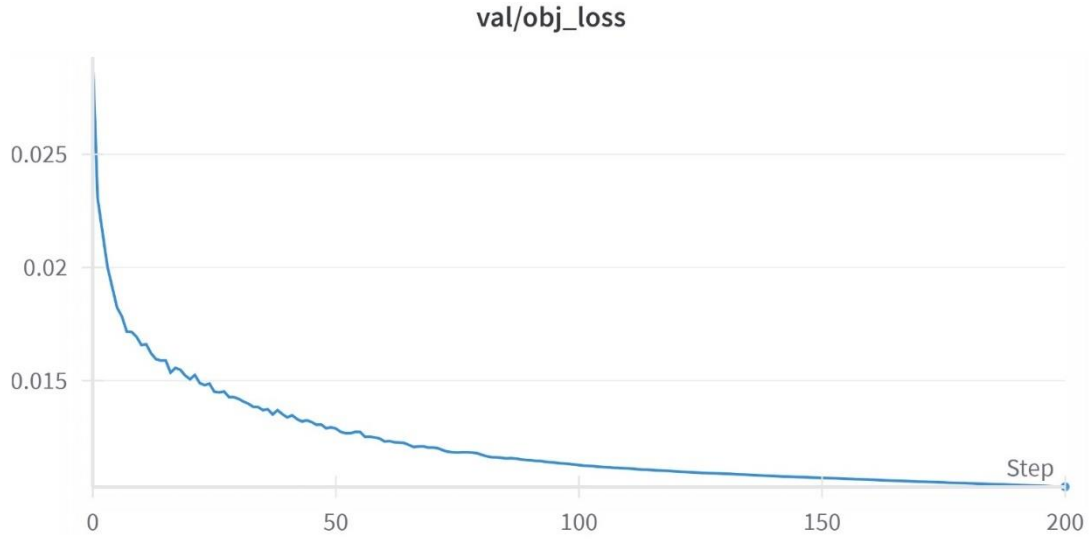


**Şekil 3.2- Modelin Sınıflandırma Performansına Ait Karmaşıklık Matrisi**

### 3.3. Kayıp Fonksiyonları ve Öğrenme Eğrisi

Modelin doğrulama verisi üzerindeki nesne tespiti başarısını ölçen `obj_loss` (nesne kaybı) metriği incelendiğinde, eğitim süreci ilerledikçe bu değer azaldığı ve modelin daha doğru tespitler yaptığı anlaşılmaktadır. Özellikle ilk 45 epoch boyunca kaydedilen değerler incelendiğinde, loss fonksiyonlarının düşüş trendi doğrultusunda modelin tutarlı bir öğrenme gerçekleştirdiği görülmektedir. Eğitim sırasında kaydedilen metrik değerleri CSV formatında saklanmış, grafiklerle de analiz edilmiştir.





**Şekil 3.3- Nesne Tespit Kayıp Fonksiyonu (val/obj\_loss) Grafiği**

Modelin doğrulama seti üzerindeki nesne kaybı değerleri her epoch boyunca azalarak istikrarlı bir öğrenme gerçekleştirdiğini göstermektedir.

### 3.4. İnfereans (Tahmin) Sonuçları Üzerine Gözlemler

Modelin test görüntüleri üzerindeki bazı tahmin sonuçları, sınıflar arası karışıklığın yanı sıra düşük confidence skorları ile dikkat çekmiştir. Örneğin, “gloves” sınıfı bazı görüntülerde hiç tespit edilememiş; “vest” ve “human” sınıfları aynı anda yanlış tahmin edilmiştir. Bu durum özellikle arka plan karmaşık yapıya sahip olduğunda ya da veri çeşitliliği yetersiz kaldığında gözlemlenmiştir.

Aşağıdaki iki görsel, eğitilen YOLOv5 modelinin tahmin çıktılarından örnekler içermektedir. Her iki örnekte de model, “helmet”, “mask” ve “human” sınıflarını yüksek doğrulukla tespit etmiştir. Bununla birlikte, “vest” sınıfına ait tahminlerde dikkat çeken bazı kararsızlıklar gözlemlenmiştir.



**Şekil 3.4 - Modelin Tahmin Sonuçlarına Ait Görsel Örnek**

İlk örnekte (solda), model “vest” sınıfı için çok düşük confidence skoru (0.0) vermiştir. Aynı kişi üzerinde birden fazla “human” etiketi algılanmış ve sınıflar kısmen çakışmıştır. İkinci örnekte (sağda), “vest” nesnesi birden fazla kutuyla (0.32 ve 0.33 confidence) işaretlenmiş, bu da modelin ilgili sınıfı tam olarak ayırt etmekte zorlandığını göstermektedir. Bu durum, hem “vest” sınıfının görsel olarak farklı varyasyonlara sahip olmasından hem de etiketleme sırasında oluşabilecek sınır belirsizliklerinden kaynaklanıyor olabilir.

Buna rağmen, kask ve maske gibi belirgin formlara sahip nesneler model tarafından yüksek doğrulukla algılanabilmektedir. Bu, modelin bazı KKD sınıflarında yüksek başarımlar gösterdiğini, ancak benzer görünüme sahip sınıflarda daha fazla örneğe ve veri çeşitliliğine ihtiyaç duyduğunu göstermektedir.

#### 4. SONUÇLAR

Bu çalışmada, sanayi ve inşaat gibi güvenlik önceliği taşıyan iş alanlarında, çalışanların kişisel koruyucu donanım (KKD) kullanımını denetlemek ve yetkisiz erişimi engellemek amacıyla çift aşamalı bir görüntü işleme sistemi geliştirilmiştir. Sistem, ilk aşamada YOLOv5 tabanlı nesne algılama ile KKD ekipmanlarının varlığını tespit etmekte; ikinci aşamada ise OCR teknolojisi kullanılarak kimlik doğrulama gerçekleştirmeyi

hedeflemektedir.

Proje kapsamında oluşturulan yaklaşık 18.000 görselden oluşan veri seti, çeşitli ortamlardan toplanan gerçek KKD görüntülerini içermektedir. Görseller; helmet (kask), vest (yelek), gloves (eldiven), mask (maske), human (insan) ve background (arka plan) olmak üzere altı sınıfta etiketlenmiştir. Bu veri setiyle eğitim süreci Google Colab Pro ortamında, T4 GPU desteğiyle tamamlanmıştır. Eğitimde kullanılan hiperparametreler dikkatlice seçilmiş ve modelin doğruluğunu optimize edecek şekilde ayarlanmıştır.

Elde edilen sonuçlara göre; model, helmet, gloves ve mask sınıflarında yüksek doğruluk oranları (%98–99) ile başarılı tahminler gerçekleştirmiştir. Buna karşın, human ve vest sınıflarında belirli düzeyde sınıf karışıklığı ve arka planla karıştırma sorunları gözlemlenmiştir. Özellikle "vest" sınıfına ait bazı tahminlerde düşük güven skorları ve çakışan sınıflandırmalar dikkat çekmiştir. Bu durum, sınıf benzerlikleri, veri setindeki örnek dağılımı ve etiketleme hassasiyeti ile doğrudan ilişkilendirilebilir.

Ara rapor kapsamında elde edilen bu bulgular, geliştirilen sistemin KKD denetimi açısından pratik ve güvenilir bir temel sunduğunu göstermektedir. Projenin devam eden aşamalarında OCR modülü ile kimlik doğrulamanın entegre edilmesi, sistemin saha testleriyle değerlendirilmesi ve modelin daha karmaşık ortamlara uyarlanabilmesi için veri setinin çeşitlendirilmesi planlanmaktadır.

## KAYNAKLAR

- [1] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 779–788.
- [2] Jocher, G. et al. (2020). YOLOv5 by Ultralytics. GitHub repository: <https://github.com/ultralytics/yolov5>
- [3] Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C.Y., & Berg, A.C. (2016). SSD: Single Shot MultiBox Detector. European Conference on Computer Vision (ECCV), 21–37.
- [4] Smith, L. N. (2018). A disciplined approach to neural network hyper-parameters: Part 1- learning rate, batch size, momentum, and weight decay. arXiv preprint arXiv:1803.09820.

- [5] Wang, C.Y., Bochkovskiy, A., & Liao, H.Y.M. (2021). YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors. arXiv:2207.02696.
- [6] Tzutalin (2015). LabelImg: Graphical Image Annotation Tool and Label Object Bounding Boxes in Images. GitHub repository: <https://github.com/tzutalin/labelImg>
- [7] Google (2023). Google Colab Pro Documentation. <https://colab.research.google.com/signup>
- [8] Roboflow (2023). Public Datasets and Dataset Management Platform. <https://roboflow.com>
- [9] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.